

ClubOS — Assistente IA (ajuda + dados)

Plano de implementação · versão 1 · 26/09/2026

Âmbito: chatbot no backoffice (shell de administração) que responde a perguntas de ajuda e a perguntas sobre os dados do clube, com custo zero nesta fase, respeitando o tenant (organização) e o papel do utilizador.

Baseado na análise read-only do repositório C:\Projetos_WEB\ClubOS (commit 0bc47df) e em fontes públicas consultadas em 26/09/2026.

1. Resumo (recomendação)

Decisão	Recomendação
Fornecedor no lançamento	Groq — plano gratuito (Free Plan), API compatível OpenAI. Ativar Zero Data Retention (Data Controls).
Modelo	openai/gpt-oss-20b (open-weights, tool calling). Alternativa no Groq free: qwen/qwen3.8-27b.
Fallback automático	Hugging Face Inference Providers (router OpenAI-compatível https://router.huggingface.co/v1) com o mesmo modelo "openai/gpt-oss-20b:cheapest"; usa os créditos mensais grátis (0,10 USD) e depois pay-as-you-go.
Desenvolvimento local	Ollama no PC do Pedro (16 GB RAM, RTX 3050 4 GB): qwen3:4b (2,5 GB) ou qwen3:8b (5,2 GB) em http://localhost:11434/v1 . Sem custos nem dados a sair do PC.
Não usar em produção	Gemini free (termos proíbem servir utilizadores no EEE com serviços não pagos + conteúdo usado para treino); Mistral Experiment e OpenRouter :free (limites baixos / treino por omissão ou dependente do fornecedor).
Arquitetura	Novo módulo NestJS "assistant": o LLM só chama ferramentas (tools) de uma whitelist, só de leitura. organizationId e papel vêm sempre da sessão (OrganizationContextGuard), nunca dos argumentos do modelo. O LLM nunca escreve SQL.
Pesquisa de ajuda	PostgreSQL full-text search (config "portuguese") sobre help_articles. pgvector + embeddings só numa fase posterior.
Troca de fornecedor	Apenas .env: LLM_BASE_URL, LLM_MODEL, LLM_API_KEY (+ LLM_FALLBACK_*).
Esforço	≈ 92 h (+4 h de preparação): Fase 1 MVP ajuda ≈ 36 h · Fase 2 ferramentas de dados ≈ 34 h · Fase 3 polimento ≈ 22 h.

Descobertas relevantes no repositório

- **Tenancy:** multi-tenant por linha (organizationId em Member, QuotaPlan, Payment, Communication, ...). O OrganizationContextGuard (APP_GUARD global) resolve a org ativa (header x-organization-id → cookie clubes_active_org → sessão → host → 1.ª membership) e valida-a contra OrganizationMember; o EffectiveRoleGuard aplica @StaffOnly/@AdminOnly. É exatamente o contexto que o chatbot deve reutilizar.
- **Papéis:** imperador (super-admin global), administrador, tesoureiro (staff, por org via OrganizationMember.orgRole) e socio (portal, global). Definidos em packages/shared/src/index.ts.
- **Módulos por org:** catálogo Module + OrganizationModule e ModuleGuard/@RequireModule — o assistente pode ser um módulo ativável por clube.
- **Quotas em atraso** não são uma coluna: são calculadas em código (computeQuotaSituation em members/quota.util.ts + dias_aviso_quota). As ferramentas devem reutilizar esta lógica (members-quota-filter.ts, dashboard.service.ts) para dar os mesmos números que o Dashboard.
- **Recibos** não têm tabela própria: Payment.receiptKey + geração assíncrona BullMQ (payments/receipt.worker.ts) com estado em Redis.
- **Rate limit** existente (express-rate-limit + Redis) cobre só /api/auth e /api/validate — o chat precisa de limites próprios.
- **Segurança:** cookies.txt está versionado no git (commit 91c816b). Hoje só contém o cabeçalho Netscape (sem cookies), mas deve ser removido do repositório e adicionado ao .gitignore para evitar que uma sessão real seja commitada no futuro. O .env está corretamente ignorado.

- **Modelos Prisma:** 16 modelos (User, Session, Account, Verification, Passkey, Organization, OrganizationMember, OrganizationSetting, Module, OrganizationModule, AuditLog, Member, QuotaPlan, Payment, QuotaReminderSent, Communication) e 3 migrações.

2. O que o chatbot vai fazer

Tipo	Exemplos de perguntas	Como responde
A) Ajuda / como fazer	• Como emito um recibo? • Como importo sócios de um Excel? • Como crio um plano de quotas trimestral? • Como dou acesso ao portal a um sócio? • Como envio uma comunicação aos sócios em atraso?	Ferramenta pesquisar_ajuda (FTS em help_articles) → resposta curta com passos + link para o artigo/página (ex.: /payments).
B) Dados do clube	• Quantos sócios têm quotas em atraso? • Quantos sócios ativos temos? • Quanto recebemos este mês vs. o mês passado? • Quantos pagamentos por MB WAY em setembro? • Quantos sócios estão no plano "Anual"? • Quem são os 10 sócios com mais dias em atraso?	Ferramentas de leitura com agregados, sempre filtradas pela org ativa e pelo papel. Nomes só quando o papel o permite e a política da org o autoriza.
Fora de âmbito	Apagar/editar dados, enviar emails, perguntas gerais não relacionadas, dados de outro clube	Recusa educada + sugestão da página certa. Não há ferramentas de escrita.

3. Arquitetura

- **1. UI (Next.js):** botão "Assistente" no header do shell (apps/web/src/app/(app)/layout.tsx, ao lado do HelpGuideButton) abre um painel lateral. Envia POST /api/assistant/chat com cookies de sessão + header x-organization-id (já feito por lib/api.ts).
- **2. Guards existentes:** Better Auth AuthGuard → OrganizationContextGuard (define req.activeOrganizationId e req.effectiveRole) → EffectiveRoleGuard (@StaffOnly) → ModuleGuard (@RequireModule("assistant")).
- **3. AssistantController:** valida o DTO (mensagem ≤ 1000 caracteres), aplica rate limit Redis, cria/recupera a conversa, abre stream SSE.
- **4. AssistantService (loop de tool calling):** monta system prompt fixo + histórico curto + lista de tools filtrada pelo papel → chama o LLM → se vier tool_calls, executa cada tool no servidor com ctx {organizationId, userId, role} da sessão → devolve o resultado (JSON compacto) ao LLM → repete até resposta final (máx. 4 iterações).
- **5. ToolRegistry:** whitelist fixa de ferramentas só de leitura; cada uma declara JSON Schema dos argumentos (sem organizationId), papel mínimo e módulo exigido; reutiliza os serviços existentes (DashboardService, MembersService, PaymentsService, ...).
- **6. LlmClient:** cliente OpenAI-compatível (SDK "openai" com baseURL) → fornecedor principal; em 429/5xx/timeout tenta o fallback.
- **7. Persistência/auditoria:** chat_conversations, chat_messages, chat_usage + AuditLog (action "assistant.tool_call").

Componente	Onde	Responsabilidade
ChatWidget	apps/web/src/components/assistant/*	UI, streaming, sugestões
AssistantController	apps/api/src/modules/assistant/assistant.controller.ts	Endpoints, SSE, DTO, rate limit
AssistantService	.../assistant/assistant.service.ts	Loop LLM ↔ tools, limites, persistência
ToolRegistry + tools	.../assistant/tools/*	Whitelist, RBAC por tool, execução
LlmClient	.../assistant/llm/llm-client.ts	Chat Completions OpenAI-compatível + fallback
HelpArticlesService	.../assistant/help/help-articles.service.ts	FTS português em help_articles
Fornecedor LLM	Groq / HF router / Ollama	Só recebe texto; nunca acede à BD

4. Opções de IA gratuitas (verificadas em 26/09/2026)

Fornecedor	Modelos úteis	Limites grátis (fonte oficial)	OpenAI-compat.	Privacidade / treino
Groq (Free Plan)	openai/gpt-oss-20b, openai/gpt-oss-120b, qwen/qwen3.8-27b	30 RPM · 1K pedidos/dia · 8K tokens/min · 200K tokens/dia (por modelo, por organização)	Sim	Não retém inputs/outputs por omissão; logs até 30 dias só para fiabilidade/abuso; ZDR ativável. Dados guardados nos EUA (SCC).
Hugging Face Inference Providers	openai/gpt-oss-20b/120b, Qwen/Qwen3-235B-A22B-Instruct-2507, Qwen3-8B/14B/32B, Llama-3.3-70B (via Groq, Novita, Nscale, DeepInfra, ...)	0,10 USD/mês de créditos (conta free, "subject to change"); PRO 2 USD/mês; depois pay-as-you-go ao preço do fornecedor, sem margem HF	Sim — router.huggingface.co/v1 (só chat)	HF não guarda corpo do pedido/resposta nem treina; logs 30 dias sem dados. Aplica-se também a política do fornecedor escolhido.
HF "Serverless" (hf-inference)	Sobretudo modelos pequenos/CPU (embeddings, classificação)	Consome os mesmos créditos	Parcial	Útil para embeddings (fase pgvector), não para o chat.
Ollama (local)	qwen3:4b (2,5 GB), qwen3:8b (5,2 GB), gpt-oss:20b	Ilimitado; limitado pelo hardware	Sim — localhost:11434/v1 (tools e streaming suportados; tool_choice não)	Dados não saem da máquina. VPS Hostinger só CPU: possível mas lento (não testado).
Google Gemini API (free)	gemini-3.x Flash / Flash-Lite, Gemma 4	Limites por projeto, visíveis só no AI Studio (não publicados na página)	Sim (beta)	Free: conteúdo usado para melhorar produtos. Termos: só serviços pagos ao disponibilizar a utilizadores no EEE/Suíça/RU → excluído para produção.
Mistral (Experiment)	Mistral Small/Large	Não confirmado na doc oficial (fontes de terceiros: ~1 pedido/s, 1B tokens/mês)	Sim	Pedidos podem ser usados para treino por omissão; opt-out em Admin › Privacy. Empresa na UE.
OpenRouter (:free)	Vários modelos ":free" (varia)	50 pedidos/dia (1000/dia após comprar ≥10 créditos); RPM ~20 (terceiros)	Sim	Depende do fornecedor; é preciso excluir fornecedores que treinam nas definições de privacidade.

Modelos recomendados (tool calling + português)

Modelo	Tamanho	Onde (grátis)	Notas
openai/gpt-oss-20b	20B (open-weights)	Groq free, HF router, Ollama	Mesmo modelo nos três ambientes → comportamento consistente. Suporta tools em 4 fornecedores no HF.
qwen/qwen3.8-27b	27B	Groq free, HF router	Família Qwen: forte em tools e multilingue. Alternativa principal.
Qwen3-8B / qwen3:8b	8,2B	Ollama (dev), HF (Nscale)	Card oficial: 100+ línguas, "expertise in agent capabilities". Desativar thinking (/no_think) para latência.
qwen3:4b	4B (2,5 GB)	Ollama	Cabe na RTX 3050 4 GB do PC do Pedro. Bom para testes do loop, qualidade inferior.
Qwen3-235B-A22B-Instruct-2507	235B MoE (22B ativos)	HF router (créditos)	Fallback de alta qualidade quando houver orçamento.
Llama-3.3-70B-Instruct	70B	HF router (créditos)	Tools suportadas; português aceitável; mais caro que gpt-oss-20b.

Recomendação: Groq free + openai/gpt-oss-20b no lançamento (piloto com poucos clubes); fallback HF router com o mesmo modelo; Ollama qwen3 para desenvolvimento. Para escalar: (1) ativar o plano pago Developer do Groq ou comprar créditos HF — mesmo código; (2) mais tarde, self-host com vLLM/Ollama numa máquina com GPU e apontar LLM_BASE_URL para lá.

Nota sobre a capacidade real: o limite que mais aperta no Groq free é 200K tokens/dia. Com ~3–4K tokens de entrada por chamada (prompt + schemas das tools + histórico) e ~2 chamadas por pergunta de dados, estimo ≈ 25–30 perguntas de dados/dia no total da plataforma (estimativa, a medir com chat_usage). Os 0,10 USD do HF dão para ~500 chamadas/mês ao preço atual do gpt-oss-20b na Novita (0,04/0,15 USD por 1M tokens in/out, listagem /v1/models do router).

5. Ferramentas (tools) propostas

Todas só de leitura. Nenhuma aceita organizationId/userId: o handler recebe ctx = {organizationId: req.activeOrganizationId, userId, role: req.effectiveRole}. Papéis: T = tesoureiro+ (StaffOnly: imperador, administrador, tesoureiro); A = AdminOnly (imperador, administrador).

Nome	O que faz (reutiliza)	Parâmetros (validados)	Papel mín. • módulo	Dados devolvidos
pesquisar_ajuda	FTS português em help_articles filtrado por papel (HelpArticlesService)	consulta: string ≤ 200	Todos • —	Até 3 artigos: título, slug, excerto (ts_headline), link
resumo_clube	Indicadores do Dashboard (DashboardService.stats)	—	T • dashboard	nº sócios, ativos, em atraso, a vencer, receita total/mês/mês anterior, variação % (sem recentPayments)
contar_socios	Contagem de Member por estado/plano	estado?: ACTIVE INACTIVE; planold?: cuid	T • members	{ total }
contar_quotas_por_situacao	computeQuotaSituation + dias_aviso_quota (members-quota-filter.ts)	situacao: overdue due_soon up_to_date no_plan pending; planold?	T • members	{ situacao, total } e, se overdue, média/máx. de dias em atraso
listar_socios_em_atraso	MemberQuotaReportService.overdueRows	limite: 1-20 (default 10); ordenar: dias numero	T • reports (+ política da org)	nº sócio, nome, plano, dias em atraso, vencimento — sem email/telefone
receitas_periodo	aggregate/groupBy de Payment PAID	de, ate: YYYY-MM-DD (máx. 24 meses); agrupar?: mes metodo plano	T • payments	Somas e contagens por grupo (EUR)
contar_pagamentos	count de Payment	estado?: PENDING PAID CANCELLED REFUNDED; metodo?: CASH TRANSFER CARD MBWAY OTHER; de?, ate?	T • payments	{ total, soma }
listar_planos_quota	MembershipPlansService.list	apenasAtivos?: boolean	T • membership-plans	nome, valor, periodicidade, ativo, nº sócios
procurar_socio	Member por nº exato ou nome (contains, máx. 5)	numero? nome? (≥3 caracteres)	T • members	nº, nome, estado, plano, situação da quota, último pagamento — sem contactos/notas
estado_recibo	PaymentsService.findOne + getReceiptStatus	pagamentold: cuid	T • payments	estado do recibo + link para /payments (o ficheiro não passa pelo LLM)
resumo_comunicacoes	CommunicationsService.list	limite: 1-10	A • communications	assunto, audiência, destinatários, enviados/falhados, estado, data
modulos_ativos	ModulesService (enabled)	—	Todos (staff) • —	Lista de módulos ativos (para explicar porque algo não aparece)

- Portal do sócio (fase futura, opcional): minha_situacao_quota (papel socio, módulo member-portal) — só o próprio Member ligado ao userId.
- Regra de ouro: resultados com dados pessoais são truncados (máx. 20 linhas) e nunca incluem campos de texto livre (Member.notes) — reduz RGPD e prompt injection.
- Cada tool tem teste unitário "cross-tenant": com ctx de org A nunca devolve dados de org B, mesmo que o modelo tente passar IDs de B (findFirst com { id, organizationId }).

6. Segurança e permissões

Tema	Medidas
Isolamento de tenant	• organizationId só de req.activeOrganizationId (já validado contra OrganizationMember). • Schemas das tools com additionalProperties:false e sem campos de tenant; qualquer ID recebido é procurado com where {id, organizationId}. • Conversas ligadas a (organizationId, userId); trocar de org no OrgSwitcher inicia nova conversa. • Imperador: pode usar em qualquer org selecionada, mas tudo fica auditado com a org.
Papéis	• Controller com @StaffOnly(); socio fica de fora (o layout (app) já redireciona sócios). • Lista de tools enviada ao LLM filtrada por papel e módulos ativos (o modelo nem vê o que não pode usar). • Re-verificação no momento da execução (papel mínimo + módulo), igual à lógica do ModuleGuard.
Prompt injection	• System prompt fixo no servidor; texto do utilizador só no papel "user"; resultados de tools como JSON delimitado e tratado como dados.

Tema	Medidas
	- Sem tools de escrita/envio → injeção não consegue causar ações. - Não devolver texto livre de terceiros (notas, corpo de comunicações). - Máx. 4 iterações, máx. 800 tokens de saída, mensagem ≤ 1000 caracteres, histórico ≤ 10 mensagens. - UI renderiza texto (sem dangerouslySetInnerHTML); links só internos (whitelist de rotas). - Opcional fase 3: classificador meta-llama/llama-prompt-guard-2-86m (disponível no Groq free).
Rate limits	- Redis (RedisModule existente, KEY_PREFIX): por utilizador 15 mensagens/10 min; por org 150/dia; global de chamadas LLM/dia abaixo do limite do fornecedor (ex.: 900 para 1K RPD do Groq). 429 com mensagem pt-PT; ao atingir o global usa o fallback ou responde "indisponível".
Auditoria / logs	- chat_messages guarda pergunta, resposta, tool, argumentos, tokens, modelo, fornecedor, latência. - AuditLog "assistant.tool_call" (tool + args, sem resultados) — visível na página /audit. - Sentry já existe (apps/api/src/sentry.ts): capturar erros do LLM sem conteúdo das mensagens.
RGPD	- Fornecedor LLM = subcontratante: atualizar /privacidade e /dpa (apps/web/src/app/privacidade, dpa) com Groq/HF, finalidade e transferência para os EUA (SCC). - Minimização: agregados por defeito; tools com nomes desligadas até a org ativar (OrganizationSetting "assistente_dados_pessoais"); nunca email/telefone/notas. - Sem treino: Groq não retém por omissão (+ZDR); HF não guarda corpos. Gemini free proibido (EEE). - Retenção: apagar conversas após 90 dias (cron @nestjs/schedule, já registado no AppModule). - Direitos: incluir conversas no export de dados do utilizador staff; cascade ao apagar User; o erasePersonalData (member-gdpr.service.ts) não precisa de mudança porque as respostas não guardam dados de sócios além do texto gerado — mas recomenda-se purgar mensagens que cite o sócio (pesquisa por n°/nome). - Aviso visível no widget: "As perguntas são processadas por um fornecedor de IA externo. Não introduza dados sensíveis."

7. Base de dados (nova migração)

Ficheiro: packages/database/prisma/migrations/20261001000000_assistant/migration.sql + modelos em packages/database/prisma/schema.prisma. Relações com Organization (onDelete: Cascade) e User.

Tabela	Campos	Índices / notas
chat_conversations	id (cuid) · organizationId · userId · title? · createdAt · updatedAt · archivedAt?	(organizationId, userId, updatedAt). Cascade ao apagar Organization/User.
chat_messages	id · conversationId · organizationId · role (user assistant tool) · content (text) · toolName? · toolArgs (Json?) · toolResultMeta (Json? — só contagens/tamanho) · model? · provider? · tokensIn? · tokensOut? · latencyMs? · feedback? (-1 1) · flagged (bool) · createdAt	(conversationId, createdAt), (organizationId, createdAt) para retenção.
help_articles	id · slug (unique) · title · body (markdown) · category · roles (text[] — quem pode ver) · module? (slug) · locale ("pt-PT") · published · organizationId? (null = global) · search tsvector GENERATED · createdAt · updatedAt	search = setweight(to_tsvector('portuguese', title), 'A') setweight(to_tsvector('portuguese', body), 'B'); índice GIN. Prisma: Unsupported("tsvector") + SQL manual.
chat_usage	id · organizationId · userId? · day (date) · requests · llmCalls · tokensIn · tokensOut · errors · fallbackCalls	unique (organizationId, userId, day). Base para quotas e custos.

- Consulta FTS: \$queryRaw com websearch_to_tsquery('portuguese', \$1), ts_rank e ts_headline; filtro published = true, locale, (organizationId IS NULL OR = org) e roles && ARRAY[papel].
- Acentos: opcional extensão unaccent via função IMMUTABLE wrapper (não é necessária no MVP).
- Porquê FTS primeiro: zero custo, zero infraestrutura nova, ~10–30 artigos curtos, termos previsíveis ("recibo", "quota", "importar"); determinístico e fácil de testar. pgvector + embeddings (ex.: modelo multilingue via HF hf-inference ou Ollama) só se as métricas de "sem resultado" o justificarem — exige imagem Postgres com pgvector (o docker-compose usa postgres:16-alpine).
- Seed: artigos iniciais em packages/database/prisma/seed.ts (ou ficheiros markdown em docs/ajuda/importados por script).
- Catálogo de módulos: adicionar { slug: "assistant", category: BASE } ao seed para ativar por clube na página /modules (imperador).

8. Backend NestJS

Ficheiro (apps/api/src/modules/assistant/)	Conteúdo
assistant.module.ts	Importa PrismaModule, RedisModule, AuditModule, DashboardModule, MembersModule, PaymentsModule, MembershipPlansModule, ReportsModule, CommunicationsModule, ModulesModule; registar em app.module.ts
assistant.controller.ts	@Controller("api/assistant") @RequireModule("assistant") @UseGuards(ModuleGuard) @StaffOnly()
assistant.service.ts	Loop tool calling, montagem do prompt, limites, persistência, SSE events
llm/llm-client.ts · llm/llm.config.ts	SDK "openai" (nova dependência) com baseUrl/apiKey/model do .env; timeout, retry 1x, fallback
tools/tool.types.ts · tools/tool-registry.ts	Interface {name, description, parameters (JSON Schema), minRoles, module?, handler(ctx,args)}; filtragem por papel/módulo
tools/*.tool.ts	Uma por ferramenta da secção 5 + *.spec.ts (Vitest)
help/help-articles.service.ts · help/help-articles.controller.ts	FTS; CRUD de artigos @ImperadorOnly() (fase 3)
chat-rate-limit.service.ts	Contadores Redis (INCR + EXPIRE) por user/org/global
assistant-retention.scheduler.ts	@Cron diário: apagar mensagens > CHAT_RETENTION_DAYS
prompts/system-prompt.pt.ts	System prompt pt-PT (âmbito, recusas, formato curto, nunca inventar números)
dto.ts	ChatRequestDto {conversationId?, message (≤1000)}, FeedbackDto
packages/shared/src/assistant.ts	Tipos partilhados dos eventos SSE (token, tool_start, tool_end, done, error)
test/e2e/assistant-rbac.e2e-spec.ts	Baseado em rbac-isolation.e2e-spec.ts: tesoureiro vs admin, org A vs B, LLM mockado

Endpoints

Método e rota	Descrição
POST /api/assistant/chat	Envia mensagem; resposta text/event-stream (tokens + eventos de tool). Cria conversa se não houver conversationId
GET /api/assistant/conversations	Lista conversas do utilizador na org ativa (paginado)
GET /api/assistant/conversations/:id	Mensagens (só role user/assistant)
DELETE /api/assistant/conversations/:id	Apaga conversa (própria)
GET /api/assistant/suggestions?page=/members	Perguntas sugeridas por papel, página e módulos ativos
POST /api/assistant/messages/:id/feedback	👍/👎 para avaliar qualidade
GET /api/assistant/usage	@AdminOnly: uso do mês da org (chat_usage)

Variáveis de ambiente (.env.example)

Variável	Exemplo	Notas
ASSISTANT_ENABLED	true	Desliga tudo rapidamente
LLM_BASE_URL	https://api.groq.com/openai/v1	Ollama: http://localhost:11434/v1 · HF: https://router.huggingface.co/v1
LLM_API_KEY	(segredo)	Ollama ignora; nunca commitar
LLM_MODEL	openai/gpt-oss-20b	Ollama: qwen3:8b · HF: openai/gpt-oss-20b:cheapest
LLM_FALLBACK_BASE_URL / _API_KEY / _MODEL	https://router.huggingface.co/v1 · hf_... · openai/gpt-oss-20b:cheapest	Opcional
LLM_TIMEOUT_MS · LLM_MAX_TOKENS · LLM_TEMPERATURE	20000 · 800 · 0.2	
ASSISTANT_MAX_TOOL_ITERATIONS	4	
ASSISTANT_RATE_USER_PER_10MIN · _ORG_PER_DAY · _GLOBAL_LLM_CALLS_PER_DAY	15 · 150 · 900	Ajustar ao plano do fornecedor
ASSISTANT_RETENTION_DAYS	90	RGPD
ASSISTANT_DATA_TOOLS_ENABLED	false (Fase 1) → true (Fase 2)	Feature flag

9. Frontend (Next.js 16 / React 19)

- **Entrada:** AssistantButton no header de apps/web/src/app/(app)/layout.tsx (junto a HelpGuideButton), visível só para staff (isStaffRole) e se "assistant" estiver em /modules/enabled.

- **Painel:** drawer lateral (desktop 420 px, mobile ecrã inteiro) com useDialogA11y existente; componentes em apps/web/src/components/assistant/ (assistant-panel.tsx, assistant-message.tsx, assistant-suggestions.tsx, assistant-input.tsx).
- **Streaming:** novo helper apps/web/src/lib/api-stream.ts (fetch + ReadableStream, credentials: "include", orgRequestHeaders()) e hook hooks/use-assistant-chat.ts. Mostrar "A consultar pagamentos..." nos eventos tool_start.
- **Tenant:** chave de estado por org (useTenantQueryKey) — ao trocar de org limpa a conversa.
- **Sugestões:** chips por página/papel: em /members "Quantos sócios têm quotas em atraso?"; em /payments "Quanto recebemos este mês?" e "Como emito um recibo?".
- **Formatação:** texto simples com listas/negrito (parser mínimo) ou react-markdown (nova dependência, sem HTML bruto); links internos via next/link.
- **Extras:** 👍/👎, botão "Nova conversa", aviso RGPD no rodapé, estado de erro com QueryErrorCard/toast existentes.
- **Testes:** Vitest para o parser de stream; Playwright apps/web/e2e/assistant.spec.ts com API de LLM mockada (fixture tipo settings-help.spec.ts).

10. Artigos de ajuda iniciais

#	Título	Página/módulo
1	Como registar um pagamento de quota	/payments · payments
2	Como emitir, ver e reenviar um recibo	/payments · payments
3	Como adicionar ou editar um sócio	/members · members
4	Como importar sócios de um Excel (e corrigir erros)	/members · members (base: docs/IMPORT-EXCEL-ERROS.md)
5	Como criar e alterar planos de quotas (periodicidade)	/membership-plans
6	O que significa "em atraso", "a vencer" e "sem plano"	/members · dias_aviso_quota
7	Como configurar lembretes automáticos de quotas	/settings · reminders
8	Como enviar uma comunicação (email/WhatsApp) a um grupo de sócios	/communications
9	Como gerar e exportar cartões de sócio com QR	/cards · cards
10	Como dar acesso ao portal do sócio	/members · member-portal
11	Relatórios: sócios pagantes e em atraso (PDF/CSV)	/reports
12	Utilizadores e papéis (administrador vs tesoureiro) e RGPD (exportar/apagar dados)	/settings · /members

Fonte de conteúdo: docs/FAQ-CRC-VALE.md, docs/GO-LIVE-CRC-VALE.md, GettingStartedCard e os fluxos atuais. Escrever em pt-PT, 150–300 palavras, passos numerados.

11. Plano de implementação por fases

Fase	Tarefas	Horas
Fase 0 — Preparação	Contas Groq (ZDR) e HF (token fine-grained "Inference Providers"); Ollama + qwen3 no PC; spike de tool calling com gpt-oss-20b em pt-PT; remover cookies.txt do git	4
Fase 1 — MVP só ajuda	Migração (help_articles, chat_conversations, chat_messages, chat_usage) 4 h · HelpArticlesService FTS 4 h · LlmClient + fallback 4 h · Controller/Service + loop com 1 tool (pesquisar_ajuda) + SSE 6 h · rate limit + usage 3 h · widget + streaming + sugestões 7 h · 12 artigos 6 h · testes 2 h	36
Fase 2 — Ferramentas de dados	ToolRegistry com RBAC/módulos 4 h · 11 tools de leitura 14 h · auditoria AuditLog 2 h · testes unitários cross-tenant + e2e RBAC 9 h · política de dados pessoais por org 2 h · textos RGPD (/privacidade, /dpa) 3 h	34
Fase 3 — Polimento	Histórico de conversas na UI 4 h · feedback 👍/👎 2 h · retenção (cron) 2 h · conjunto de avaliação (40 perguntas) + afinação do prompt 6 h · prompt guard opcional 3 h · CRUD artigos (imperador) 3 h · docs (docs/ASSISTENTE.md) 2 h	22
Total		≈ 96 (92 sem Fase 0)

- Critério de saída Fase 1: 90% das 20 perguntas de ajuda de teste com artigo certo; p95 < 6 s.
- Critério de saída Fase 2: números iguais ao Dashboard/Relatórios; 0 fugas em testes cross-tenant; tesoureiro não vê tools de admin.

12. Custos e riscos

Custos

Cenário	Custo	Notas
Dev local (Ollama)	0 €	Hardware do Pedro
Lançamento (Groq free + HF créditos)	0 €	Até ~25-30 perguntas de dados/dia (estimativa pelo limite de 200K tokens/dia)
Crescimento (pago, mesmo modelo)	Cêntimos a poucos €/mês	Ex.: 1000 perguntas × 2 chamadas × (3K in + 300 out) com gpt-oss-20b a 0,10/0,50 USD por 1M (preço Groq listado no HF router) ≈ 0,9 USD/mês. Confirmar preços na altura.
Self-host	Custo de GPU/VPS	vLLM/Ollama numa máquina com GPU; o VPS atual (só CPU) só serve modelos pequenos e lentos

Riscos

Risco	Impacto	Mitigação
Planos grátis mudam ou acabam (HF diz "subject to change")	Alto	Fornecedor por .env; fallback; flag ASSISTANT_ENABLED
Limites diários esgotam (200K tokens/dia Groq)	Médio	Prompt compacto, tools filtradas, histórico curto, cache Redis 60 s, limite global
Modelo inventa números	Alto	Prompt "só números vindos de tools"; mostrar fonte (tool) na UI; avaliação com 40 perguntas
Fuga entre clubes	Crítico	ctx da sessão, where com organizationId, testes cross-tenant obrigatórios em CI
RGPD (dados pessoais em terceiros, EUA)	Alto	Agregados por defeito, ZDR, DPA/privacidade atualizados, retenção 90 dias
Prompt injection	Médio	Sem tools de escrita, dados como JSON, sem texto livre de terceiros
Qualidade do pt-PT (brasileirismos)	Baixo	Instrução explícita pt-PT no system prompt; testar Qwen vs gpt-oss
Latência no free tier	Baixo	Streaming, max_tokens 800, thinking desligado/baixo

Fontes consultadas (26/09/2026)

- HF Inference Providers — Pricing: huggingface.co/docs/inference-providers/pricing
- HF Inference Providers — visão geral e endpoint OpenAI: huggingface.co/docs/inference-providers/index
- HF Inference Providers — Security: huggingface.co/docs/inference-providers/security
- HF router — lista de modelos/fornecedores/preços: router.huggingface.co/v1/models
- Groq — Rate limits: console.groq.com/docs/rate-limits · Your Data: console.groq.com/docs/your-data
- Gemini — Pricing: ai.google.dev/gemini-api/docs/pricing · Rate limits: ai.google.dev/gemini-api/docs/rate-limits · OpenAI compat.: ai.google.dev/gemini-api/docs/openai · Termos: ai.google.dev/gemini-api/terms
- Ollama — OpenAI compatibility: docs.ollama.com/api/openai-compatibility · biblioteca qwen3: ollama.com/library/qwen3
- Qwen3-8B model card: huggingface.co/Qwen/Qwen3-8B
- OpenRouter — Limits: openrouter.ai/docs/api-reference/limits · FAQ: openrouter.ai/docs/faq · Provider logging: openrouter.ai/docs/guides/privacy/logging
- Mistral — opt-out de treino: help.mistral.ai/en/articles/455207 (limites do plano Experiment não confirmados em página oficial)